

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

گزارش فاز دوم پروژه

نام و نام خانوادگی اعضای تیم

علیرضا فرشی ۸۱۰۱۰۴۲۲۳

ساراسادات نصر ۸۱۰۱۰۴۲۷۲

سعید رضائی نور ۸۱۰۱۰۴۱۴۵

۱	چکیده	۱
۲	مقدمه	۲
۲	۱.۲ بیان مسئله و اهمیت موضوع	۲
۲	۲.۲ مرور کلی بر پروژه	۲
۲	۳.۲ پیش پردازش و استخراج ویژگی	۲
۳	۴.۲ مدل های یادگیری ماشین	۳
۳	۵.۲ ساختار گزارش	۳
۴	۶.۲ اهداف و دستاوردهای مورد انتظار	۴
۴	۳ پاک سازی داده و استخراج ویژگی	۴
۵	۱.۳ پاک سازی داده ها	۵
۵	۱.۱.۳ بارگذاری و یکسان سازی نرخ نمونه برداری	۵
۵	۲.۱.۳ حذف سکوت	۵
۵	۳.۱.۳ نرمال سازی دامنه	۵
۵	۴.۱.۳ افزایش داده (Data Augmentation)	۵
۶	۲.۳ ویژگی های استخراج شده و علت انتخاب آن ها	۶
۷	۱.۲.۳ ویژگی های حوزه زمان	۷
۷	۲.۲.۳ ویژگی های حوزه فرکانس	۷
۸	۳.۲.۳ ویژگی های مبتنی بر طیف نگار مل (Mel-spectrogram)	۸
۸	۴.۲.۳ ضرایب کپسترال مل (MFCC)	۸
۸	۵.۲.۳ ویژگی های کروماتیک (Chroma Features)	۸
۹	۶.۲.۳ ویژگی های تُنال (Tonnetz)	۹
۹	۷.۲.۳ ویژگی های کنتراست طیفی (Spectral Contrast)	۹

۹	ویژگی‌های چندجمله‌ای (Poly Features)	۸.۲.۳
۹	ویژگی‌های ریتمیک (Tempogram)	۹.۲.۳
۱۰	جمع بندی و مشاهده ویژگی ها	۱۰.۲.۳

فهرست تصاویر

۴	توزیع دادگان بر اساس معیارهای مختلف	۱
۶	فایل های صوتی پاک سازی شده به ازای هر زبان	۲
۱۰	ماتریس همبستگی ویژگی ها	۳
۱۱	توزیع ویژگی های مختلف بر اساس زبان ها	۴
۱۲	نمایش سه بعدی داده های صوتی بر اساس کلید ویژگی های انتخاب شده .	۵
۱۳	عنوان تصویر نمونه	۶

فهرست جداول

هدف از این پروژه، طراحی و پیاده‌سازی یک سیستم تشخیص خودکار زبان‌های گفتاری (اسپانیایی، کره‌ای، ایتالیایی و آلمانی) بر پایه یادگیری ماشین است. پس از جمع‌آوری و مشاهده کلی دادگان و پیش‌پردازش داده‌های صوتی از جمله حذف نویز یا نرمال‌سازی صوت، ویژگی‌های زیادی از جمله ویژگی‌های مبتنی بر حوزه زمان، طیف‌نگاره مقیاس‌بندی‌شده با مل و انرژی استخراج گردیده است. داده‌ها با روش نمونه‌برداری طبقه‌ای به مجموعه‌های آموزش (۸۰٪) و تست (۲۰٪) تقسیم شدند. در بخش طبقه‌بندی، مدل‌های k نزدیک‌ترین همسایه، SVM با کرنل rbf، random forest، MLP، Decision Tree، Logistic Regression و Naive Bayes با استفاده از کتابخانه Scikit-Learn پیاده‌سازی و ارزیابی شدند. نتایج ارزیابی نشان داد که k نزدیک‌ترین همسایه با دقت 98.7 درصد با مقدار k برابر با ۵، بالاترین کارایی را دارد. در بخش خوشه‌بندی بدون ناظر، الگوریتم DBSCAN با تعیین ۱۴ خوشه بهینه (مطابق تعداد زبان‌ها) و امتیاز خلوص ۱ بهترین انطباق با ساختار واقعی داده را نشان داد. همچنین کاهش ابعاد با t -SNE جداسازی نسبتاً متمایز خوشه‌ها را در فضای دو بعدی آشکار ساخت. این پژوهش گامی در جهت کاربرد پردازش سیگنال گفتار و یادگیری ماشین در شناسایی چندزبانه است.

۱.۲ بیان مسئله و اهمیت موضوع

در دنیای امروز، با توجه به گسترش ارتباطات بین‌المللی و افزایش محتوای چندزبانه در فضای دیجیتال، تشخیص خودکار زبان گفتاری به یکی از چالش‌های مهم در حوزه پردازش سیگنال و یادگیری ماشین تبدیل شده است. کاربردهای این فناوری از سیستم‌های ترجمه همزمان و دستیارهای صوتی هوشمند گرفته تا برچسب‌گذاری خودکار محتوای صوتی و پالایش اطلاعات در پلتفرم‌های چندزبانه گسترده است. با توجه به تنوع زبانی موجود در داده‌های صوتی کتابخانه‌های دیجیتال و پادکست‌ها، توسعه سیستمی که بتواند با دقت بالا زبان گفتاری را شناسایی کند، گامی اساسی در جهت سازماندهی و بازیابی مؤثر اطلاعات به شمار می‌رود.

۲.۲ مرور کلی بر پروژه

در این پروژه، مجموعه‌ای از داده‌های صوتی شامل قطعات کوتاه (حدود یک دقیقه) از کتاب‌های صوتی به چهار زبان اسپانیایی، کره‌ای، ایتالیایی و آلمانی مورد استفاده قرار گرفته است. هدف اصلی، طراحی و پیاده‌سازی یک سیستم کامل مبتنی بر یادگیری ماشین است که قادر به تشخیص زبان گفتاری در این قطعات صوتی باشد. برای این منظور، پروژه در چند گام اصلی شامل پاک‌سازی داده‌ها، استخراج ویژگی، طبقه‌بندی و خوشه‌بندی طراحی شده است.

۳.۲ پیش‌پردازش و استخراج ویژگی

صداهاى خام به دليل وجود نویز و تفاوت در بلندی صدا، مستقیماً برای مدل‌های یادگیری ماشین قابل استفاده نیستند. از این رو، در گام نخست، عملیات پیش‌پردازش شامل نویززدایی و نرمال‌سازی دامنه بر روی داده‌ها اعمال می‌گردد تا کیفیت ورودی بهبود یابد. در ادامه، با استفاده از روش‌های استخراج ویژگی، سیگنال‌های صوتی به بردارهای عددی معنادار تبدیل می‌شوند. ویژگی‌های مرسوم هم‌چون ضرایب کپسترال مل (MFCC)، طیف‌نگار، انرژی و نرخ عبور از صفر از جمله شاخص‌هایی هستند که می‌توانند تفاوت بین زبان‌های مختلف را به خوبی نمایش

دهند.

۴.۲ مدل‌های یادگیری ماشین

پس از آماده‌سازی داده‌ها، نوبت به بخش اصلی پروژه یعنی مدل‌سازی می‌رسد. در این پروژه، سه رویکرد اصلی دنبال می‌شود:

- **طبقه‌بندی نظارت‌شده:** در این بخش، داده‌ها با برچسب زبان به مدل‌های مختلف یادگیری ماشین داده می‌شوند تا الگوهای متمایزکننده زبان‌ها را بیاموزند. الگوریتم‌هایی مانند ماشین بردار پشتیبان (SVM)، جنگل تصادفی (Random Forest) و شبکه عصبی پرسپترون چندلایه (MLP) برای این منظور پیاده‌سازی و ارزیابی می‌شوند.
- **خوشه‌بندی بدون نظارت:** برای تحلیل ساختار ذاتی داده‌ها بدون استفاده از برچسب‌ها، الگوریتم‌های خوشه‌بندی مانند K-Means و DBSCAN به کار گرفته می‌شوند تا مشخص شود آیا داده‌های صوتی به طور طبیعی بر اساس زبان گروه‌بندی می‌شوند یا خیر.
- **ارزیابی و تحلیل:** در نهایت، عملکرد مدل‌ها با معیارهایی همچون دقت (Accuracy)، فراخوانی (Recall)، صحت (Precision) و امتیاز F1 سنجیده شده و با رسم ماتریس درهم‌ریختگی، زبان‌هایی که بیشترین خطا در تشخیص آن‌ها رخ داده، شناسایی و تحلیل می‌شوند.

۵.۲ ساختار گزارش


گزارش پیش رو مطابق با مراحل پروژه سازماندهی شده است. در بخش دوم، فرآیند پاک‌سازی داده‌ها و استخراج ویژگی تشریح می‌گردد. بخش سوم به طبقه‌بندی و مدل‌های نظارت‌شده اختصاص دارد. در بخش چهارم، خوشه‌بندی و تحلیل بدون نظارت ارائه می‌شود. بخش پنجم شامل ارزیابی جامع مدل‌ها و مقایسه نتایج است و در نهایت، بخش ششم به جمع‌بندی و نتیجه‌گیری اختصاص یافته است. همچنین کدهای پیاده‌سازی شده در قالب چندین دفترچه یادداشت ژوپیتِر (ipynb) به صورت جداگانه ارائه گردیده است.

۶.۲ اهداف و دستاوردهای مورد انتظار

انتظار می‌رود که با اجرای این پروژه، ضمن آشنایی عملی با چالش‌های کار با داده‌های صوتی واقعی، بتوان سیستمی طراحی کرد که با دقت مناسبی زبان گفتاری را تشخیص دهد. همچنین تحلیل خوشه‌بندی می‌تواند نشان دهد که آیا ویژگی‌های استخراج‌شده به اندازه کافی قدرت تفکیک زبان‌ها را دارند یا نیاز به بازنگری در انتخاب ویژگی‌ها وجود دارد. مقایسه مدل‌های مختلف نیز دیدگاه روشنی نسبت به نقاط قوت و ضعف هر الگوریتم در مسئله تشخیص زبان ارائه خواهد داد.

پاک‌سازی داده و استخراج ویژگی

در این مرحله قبل از اینکه عملیات پاک‌سازی و استخراج ویژگی‌ها را انجام دهیم، دادگان را مشاهده می‌کنیم و سعی می‌کنیم اطلاعاتی کلی از آن استخراج کنیم. در شکل‌های زیر توزیع دادگان بر اساس زبان‌های مختلف، جنسیت و مدت زمان نمایش داده شده است.



شکل ۱: توزیع دادگان بر اساس معیارهای مختلف

حال در ادامه به پیش پردازش داده‌های صوتی می‌پردازیم.

۱.۳ پاک سازی داده ها

۱.۱.۳ بارگذاری و یکسان سازی نرخ نمونه برداری

ابتدا تمام فایل های صوتی با استفاده از کتابخانه Librosa بارگذاری شدند. نرخ نمونه برداری همه فایل ها به ۲۲۰۵۰ هرتز یکسان سازی گردید. این مقدار به عنوان نرخ استاندارد در بسیاری از پروژه های پردازش گفتار انتخاب می شود، زیرا تعادل مناسبی بین کیفیت سیگنال و حجم داده برقرار می کند. همچنین برای کاهش زمان پردازش و یکنواخت سازی طول نمونه ها، هر فایل صوتی تا ۵۰ ثانیه برش داده شد. این بازه زمانی برای استخراج ویژگی های معنادار کافی بوده و از ورود داده های اضافی و افزونه به مدل جلوگیری می کند.

۲.۱.۳ حذف سکوت

یکی از چالش های رایج در داده های صوتی، وجود بخش های سکوت یا نویزهای کم دامنه در ابتدا و انتهای فایل هاست. این بخش ها نه تنها اطلاعات مفیدی به مدل اضافه نمی کنند، بلکه می توانند باعث کاهش کارایی و افزایش خطا شوند. برای رفع این مشکل، از تابع librosa.effects.trim با آستانه ۲۰ دسی بل استفاده شد. این تابع با شناسایی بخش هایی که انرژی آنها کمتر از آستانه تعیین شده است، آنها را حذف کرده و تنها بخش های حاوی گفتار را نگه می دارد. انتخاب آستانه ۲۰ دسی بل بر اساس آزمایش های اولیه و مشاهده توزیع انرژی سیگنال ها صورت گرفته است.

۳.۱.۳ نرمال سازی دامنه

سیگنال های صوتی مختلف ممکن است دامنه های متفاوتی داشته باشند که این تفاوت می تواند ناشی از شرایط ضبط، فاصله میکروفون یا تنظیمات سخت افزاری باشد. برای رفع این ناهماهنگی، از نرمال سازی با استفاده از تابع librosa.util.normalize استفاده شد. این تابع دامنه سیگنال را به بازه $[-1, 1]$ مقیاس دهی می کند و تضمین می کند که تمام نمونه ها از نظر بلندی صدا در یک سطح قرار گیرند. این امر باعث می شود مدل به جای تفاوت های دامنه ای، بر روی ویژگی های زبانی متمرکز شود.

۴.۱.۳ افزایش داده (Data Augmentation)

برای بهبود تعمیم پذیری مدل و افزایش تنوع داده های آموزشی، از تکنیک های افزایش داده استفاده شد. این کار به ویژه با توجه به محدودیت حجم داده های اولیه، می تواند عملکرد مدل را به طور


چشمگیری بهبود بخشد. سه روش افزایش داده به کار گرفته شد:

- **افزودن نویز سفید:** نویز سفید با ضریب 0.05 به سیگنال اصلی اضافه شد. این کار باعث می‌شود مدل در برابر نویزهای محیطی مقاوم‌تر شده و توانایی تشخیص زبان در شرایط واقعی را بیاموزد. مقدار نویز انتخاب شده به اندازه‌ای است که تغییر محسوسی در سیگنال ایجاد کند اما گفتار را غیرقابل تشخیص نسازد.

- **کشش زمانی:** با ضریب 0.9 ، سیگنال صوتی در زمان فشرده شد. این تکنیک سرعت گفتار را تغییر می‌دهد بدون اینکه زیروبمی صدا تحت تأثیر قرار گیرد. این کار به مدل کمک می‌کند تا الگوهای زبانی را مستقل از سرعت گفتار تشخیص دهد.

- **تغییر زیروبمی صدا:** با جابجایی 2 نیم‌پرده، زیروبمی صدا تغییر داده شد. این تکنیک تفاوت‌های ناشی از جنسیت، سن و ویژگی‌های فیزیکی گویندگان را شبیه‌سازی می‌کند و باعث می‌شود مدل به این تغییرات حساس نباشد.

در نهایت خروجی بدست آمده از پاک سازی داده های صوتی در شکل زیر قابل مشاهده می باشد.



شکل ۲: فایل های صوتی پاک سازی شده به ازای هر زبان

حال در ادامه به استخراج ویژگی ها می پردازیم.

۲.۳ ویژگی های استخراج شده و علت انتخاب آن ها

در این پروژه، برای تبدیل سیگنال های صوتی خام به بردارهای عددی قابل استفاده در مدل های یادگیری ماشین، مجموعاً ۱۰۲ ویژگی از حوزه های مختلف زمانی، فرکانسی و طیفی استخراج

گردید. این ویژگی‌ها با هدف پوشش کامل جنبه‌های مختلف سیگنال گفتار شامل زیروبمی، تُن، ریتم، انرژی و ساختار فرکانسی انتخاب شده‌اند. در ادامه به تشریح هر دسته از ویژگی‌ها و دلایل انتخاب آن‌ها می‌پردازیم.

۱.۲.۳ ویژگی‌های حوزه زمان

ویژگی‌های حوزه زمان مستقیماً از سیگنال صوتی در بازه زمانی استخراج می‌شوند و اطلاعاتی درباره دامنه و نوسانات سیگنال ارائه می‌دهند:

- **نرخ عبور از صفر (Zero Crossing Rate):** این ویژگی تعداد دفعاتی را که سیگنال از صفر عبور می‌کند در واحد زمان اندازه‌گیری می‌کند. ZCR برای تشخیص نویز از گفتار و همچنین تفکیک صداهای گرفته‌دار (مانند همخوان‌ها) از صداهای کشیده (مصوت‌ها) مفید است. میانگین و انحراف معیار این ویژگی محاسبه شده است.
- **ریشه میانگین مربعات انرژی (RMS Energy):** این ویژگی میزان انرژی سیگنال را نشان می‌دهد و معیاری برای بلندی صدا محسوب می‌شود. RMS می‌تواند به تفکیک بخش‌های گفتاری از سکوت کمک کرده و تغییرات انرژی در طول زمان را نمایش دهد. میانگین و انحراف معیار این ویژگی نیز استخراج گردیده است.

۲.۲.۳ ویژگی‌های حوزه فرکانس

این ویژگی‌ها با تبدیل سیگنال به حوزه فرکانس (با استفاده از تبدیل فوریه) به دست می‌آیند و اطلاعاتی درباره توزیع انرژی در فرکانس‌های مختلف ارائه می‌دهند:

- **مرکزواره طیفی (Spectral Centroid):** این ویژگی مرکز ثقل طیف فرکانسی را نشان می‌دهد و معیاری برای زیروبمی صدا است. صداهای زیرتر مرکزواره بالاتری دارند و صداهای بم‌تر مرکزواره پایین‌تری. این ویژگی در تفکیک زبان‌ها بر اساس ساختار آوایی آن‌ها مؤثر است.
- **پهنای باند طیفی (Spectral Bandwidth):** پهنای باند، گستردگی طیف فرکانسی حول مرکزواره را اندازه‌گیری می‌کند. این ویژگی می‌تواند تفاوت بین صداهای خالص و نویزی را نشان دهد.

- **نقطه برگشت طیفی (Spectral Rolloff):** این ویژگی فرکانسی را نشان می‌دهد که درصد مشخصی از انرژی طیفی (معمولاً ۸۵٪) زیر آن قرار دارد. این ویژگی برای تشخیص نویز و تمایز بین صداهای گرفته‌دار و کشیده مفید است.

۳.۲.۳ ویژگی‌های مبتنی بر طیف‌نگار مل (Mel-spectrogram)

طیف‌نگار مل نسخه‌ای از طیف‌نگار است که بر اساس مقیاس شنوایی انسان (مقیاس مل) تنظیم شده است. گوش انسان در فرکانس‌های پایین تفکیک‌پذیری بیشتری دارد و مقیاس مل این ویژگی را شبیه‌سازی می‌کند:

- **طیف‌نگار مل:** پس از محاسبه طیف‌نگار مل، آن را به مقیاس دسی‌بل تبدیل کرده و میانگین و انحراف معیار آن استخراج شده است. این ویژگی نمای کلی از توزیع انرژی در باندهای فرکانسی مختلف ارائه می‌دهد.

۴.۲.۳ ضرایب کپسترال مل (MFCC)

MFCC ها یکی از مهم‌ترین و پرکاربردترین ویژگی‌ها در پردازش گفتار و تشخیص زبان هستند. این ویژگی‌ها با اعمال تبدیل کسینوسی گسسته بر روی طیف‌نگار مل به دست می‌آیند و ساختار کانال صوتی را به صورت فشرده نمایش می‌دهند:

- **۲۰ ضریب MFCC:** برای هر نمونه صوتی، ۲۰ ضریب اول MFCC محاسبه و میانگین و انحراف معیار هر ضریب استخراج گردید. ضریب اول معمولاً نمایانگر انرژی کلی، ضرایب بعدی نمایانگر ساختار فرمت‌ها (رزونانس‌های کانال صوتی) و ضرایب بالاتر نمایانگر جزئیات ظریف‌تر هستند. MFCC ها به دلیل توانایی بالا در مدل‌سازی ویژگی‌های آوایی، هسته اصلی بردار ویژگی این پروژه را تشکیل می‌دهند.

۵.۲.۳ ویژگی‌های کروماتیک (Chroma Features)

این ویژگی‌ها توزیع انرژی در ۱۲ کلاس نت موسیقایی را نشان می‌دهند و برای تحلیل زیروبمی و ثباتی صدا مفید هستند:

- **۱۲ ویژگی کروماتیک:** برای هر یک از ۱۲ کلاس کروماتیک، میانگین و انحراف معیار انرژی محاسبه شده است. این ویژگی‌ها می‌توانند در تشخیص زبان‌هایی که ساختار ثبات متفاوتی دارند (مانند زبان‌های آهنگین) مؤثر باشند.

۶.۲.۳ ویژگی‌های تُنال (Tonnetz)

ویژگی‌های Tonnetz (شبکه تُنال) نمایشی از مرکز ثقل تُنال در فضای ۶ بعدی هستند و روابط هارمونیک بین نت‌ها را مدل می‌کنند:

- **۶ ویژگی: Tonnetz** این ویژگی‌ها از روی ویژگی‌های کروماتیک محاسبه شده و تغییرات تُنال در طول زمان را نشان می‌دهند. میانگین و انحراف معیار هر ۶ بعد محاسبه گردیده است.

۷.۲.۳ ویژگی‌های کنتراست طیفی (Spectral Contrast)

این ویژگی‌ها تفاوت بین قله‌ها و دره‌های طیفی را در هر زیرباند فرکانسی اندازه‌گیری می‌کنند:

- **۷ زیرباند کنتراست طیفی:** برای هر زیرباند، میانگین و انحراف معیار کنتراست طیفی محاسبه شده است. این ویژگی‌ها می‌توانند ساختار هارمونیک و نویزی سیگنال را بهتر نشان دهند.

۸.۲.۳ ویژگی‌های چندجمله‌ای (Poly Features)

این ویژگی‌ها ضرایب یک چندجمله‌ای درجه ۱ هستند که بر روی پوش طیفی برازش داده می‌شود:

- **۲ ویژگی چندجمله‌ای:** ضرایب ۰ و ۱ (میانگین) استخراج گردیده که نمایانگر شیب و عرض از مبدأ پوش طیفی هستند.


۹.۲.۳ ویژگی‌های ریتمیک (Tempogram)

تمپوگرام نمایشی از سرعت و ریتم سیگنال صوتی است و برای تحلیل ضرب‌آهنگ و ریتم گفتار مفید می‌باشد:

- **تمپوگرام:** با محاسبه پوش onset و سپس تمپوگرام، میانگین و انحراف معیار آن به عنوان ویژگی‌های ریتمیک استخراج شده‌اند. این ویژگی‌ها می‌توانند در تشخیص زبان‌هایی با ریتم متفاوت (مانند زبان‌های هجایی در مقابل فشارتکیه) مؤثر باشند.


۱۰.۲.۳ جمع بندی و مشاهده ویژگی ها

حال در ادامه سعی می کنیم ویژگی های استخراج شده را ببینیم. در شکل زیر ماتریس همبستگی ویژگی ها قابل مشاهده می باشد:




شکل ۳: ماتریس همبستگی ویژگی ها

حال در ادامه نمودار توزیع ویژگی های استخراج شده به ازای هر زبان در نمودارهای شکل زیر قابل مشاهده هستند:



شکل ۴: توزیع ویژگی‌های مختلف بر اساس زبان‌ها

در نهایت نیز با انتخاب ویژگی‌های کلیدی استخراج شده و اعمال PCA روی آن‌ها به یک شکل ۳ بعدی به ازای زبان‌های مختلف رسیدیم که در زیر قابل مشاهده می‌باشد:



شکل ۵: نمایش سه بعدی داده‌های صوتی بر اساس کلید ویژگی‌های انتخاب شده

Model Performance on Training Data



Model Performance on Test Data



شکل ۶: عنوان تصویر نمونه

مراجع

در این بخش، منابعی که در تمرینات و پیاده‌سازی استفاده کرده‌اید (مانند مقالات، سایت‌ها و ...) را در یک فرمت استاندارد فهرست کنید. برای رفرنس‌دهی می‌توانید از بخش Reference در نرم‌افزار Word، سایت‌های مخصوص یا افزونه‌های مرتبط استفاده کنید. همچنین، لازم است که هر منبع استفاده‌شده را در بخش مربوطه ارجاع دهید. توجه داشته باشید که شباهت کد یا پاسخ شما به منابع دیگر باید در حد معقول باشد؛ کپی‌برداری مستقیم از منابع، مدنظر ما نیست. در صورت مشاهده کپی کامل از یک منبع، نمره آن تمرین یا بخش مربوطه به شما تعلق نخواهد گرفت.